

# Survey of disentangled representation online resource w/ illustrating examples

---

Student : Sian-Yi Chen

Advisor : Tay-Jyi Lin and Chingwei Yeh

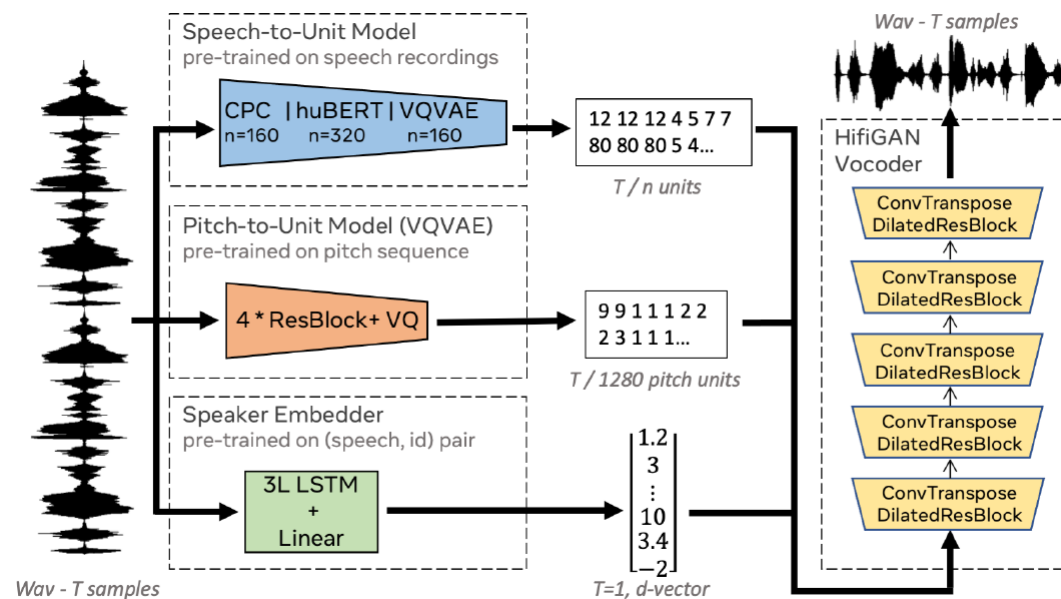
# Outline

## ● Action item

- 看看 paper 有沒有提供 open source code，並重建 github project

## ● Status report

- ① 論文並沒有提供原始碼，只有提供訓練前後的語音樣本
  - Audio samples link : <https://speechbot.github.io/resynthesis/>
- ② 在圖一語音架構中，分別用了三個編碼器，和一個解碼器，其中除了 HuBERT 與 Speaker verification 以外皆有對應論文的 open source code
  - 編碼器
    - 1) 語音內容，由三個神經網路構成
      - a. CPC [1]
      - b. HuBERT [2]，找到同為 HuBERT 但為不同論文的 code
      - c. VQ-VAE [3]
    - 2) 基本頻率 (YAAPY 演算法 [4] + VQ-VAE [3])
    - 3) 說話者 (Speaker verification [5])，為改進 [5] 的 code
  - 解碼器
    - 1) HiFi-GAN [6]
- ③ CPC GitHub source code
  - 已成功解決大部分環境問題，但還在找訓練到一半中斷的問題，猜測是 C 碟容量不足導致



(圖一) Speech resynthesis architecture

6 個神經網路模型分別引用的論文：

- [1] A. van den Oord, Y. Li, and O. Vinyals, "Representation learning with contrastive predictive coding," arXiv preprint arXiv:1807.03748, 2018.
- [2] W.-N. Hsu et al., "Hubert: How much can a bad teacher benefit ASR pre-training?" in *NeurIPS Workshop on Self-Supervised Learning for Speech and Audio Processing Workshop*, 2020.
- [3] A. van den Oord et al., "Neural discrete representation learning," in *NeurIPS*, 2017.
- [4] K. Kasi and S. A. Zahorian, "Yet another algorithm for pitch tracking," in *ICASSP*, 2002.
- [5] G. Heigold et al., "End-to-end text-dependent speaker verification," in *ICASSP*, 2016.
- [6] J. Kong et al., "Hifi-gan: Generative adversarial networks for efficient and high fidelity speech synthesis," in *NeurIPS*, 2020.

# Open source code

- 編碼器

- 1) 語音內容，使用三個神經網路構成

- a. CPC

- [GitHub - pat-coady/contrast-pred-code: Minimal implementation of Contrastive Predictive Coding for audio.](#)

- b. HuBERT (同為 HuBERT 但為不同篇論文)

- [fairseq/examples/hubert at master · pytorch/fairseq · GitHub](#)

- c. VQ-VAE

- [GitHub - 1Konny/VQ-VAE: Pytorch Implementation of "Neural Discrete Representation Learning"](#)

- 2) 基本頻率

- a. YAAPT

- [GitHub - mcraig2/pyaapt: Implementation of the YAAPT \(Yet Another Algorithm for Pitch Tracking\), an algorithm that determines the fundamental frequency of noisy signals \(speech signals, for example\).](#)

- b. VQ-VAE (論文表示與語音內容編碼器使用相同的 VQ-VAE)

- 3) 說話者

- a. Speaker verification (此為改進作者引用論文的開源碼)

- [GitHub - Janghyun1230/Speaker\\_Verification: Tensorflow implementation of generalized end-to-end loss for speaker verification](#)

- 解碼器

- a. HiFi-GAN

- [GitHub - jik876/hifi-gan: HiFi-GAN：用於高效和高保真語音合成的生成對抗網絡](#)

# CPC (Contrastive Predictive Coding)

CPC [1]，對比預測編碼，目的是使用無監督學習取得高維數據中有用的表示，像是語意或是特徵，在不使用標註資料的情況下辨識資料間的關係。

[1] 提出了 CPC 這種方法，主要思想為：

- 對比：它使用對比方法進行訓練，即主模型必須區分正確和錯誤的數據序列。
- 預測性：模型必須在給定當前上下文的情況下預測未來模式。
- 編碼：模型在潛在空間中執行此預測，將代碼向量轉換為其他代碼向量（與直接預測高維數據相反）。




Figure 1: Overview of Contrastive Predictive Coding, the proposed representation learning approach. Although this figure shows audio as input, we use the same setup for images, text and reinforcement learning.

左圖中，編碼器  $g_{enc}$  取得原始音訊樣本，並輸出向量。透過自回歸網路根據上下文向量  $c_t$  預測未來的時間步長

# Architecture

